




深度學習 Deep Learning

最佳化方法

Instructor: 林英嘉 (Ying-Jia Lin)
2026/09/30



[Course GitHub](#)




[Slido # DL0930](#)

Outline

- Recap [20 min]
- Gradient Descent (II) - Optimizers [60 min]
- Introduction to PyTorch [35 min]
- Quiz [30 min]



[Recap] 深度學習模型訓練流程



[Recap] Gradient Descent (梯度下降)

Assume x is a **trainable** parameter (**weight**), f is a **differentiable** function:

$$\text{Gradient descent: } x' = x - \eta \nabla_x f(x)$$

η is the **learning rate** (伊塔/欸塔) used for gradient descent.


- 調整每次更新參數時的幅度



[Recap] 梯度下降簡易範例

梯度下降公式： $x' = x - \eta \nabla_x f(x)$

- 使用 $f(x) = 1/2x^2$ 作為範例 (x 同樣代表模型參數，為了方便理解，暫時不考慮輸入資料點)



[Recap] Minimize a Regression Model

- 假設我們今天要用 linear regression 來訓練一層的 MLP，模型輸出是 $\hat{y} = wx + b$
- 以均方誤差 (Mean Squared Error) 為例：

$$\mathcal{L} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad \leftarrow \text{模型輸出跟正確答案的平均差距}$$

把 $(wx_i + b)$ 代入 $\hat{y}_i$ $\longrightarrow$
$$= \frac{1}{n} \sum_{i=1}^n (y_i - (wx_i + b))^2$$

- 其中：
 - 訓練目標是讓這個公式在 n 筆訓練資料的平均差距越小越好
 - $\mathcal{L}$ 代表 Loss function ; n 代表有 n 筆訓練資料
 - y_i 為任一筆 ground-truth、 $\hat{y}_i$ 為任一筆 prediction (model output)



[Recap] 利用梯度下降更新參數

$$\frac{\partial \mathcal{L}}{\partial w} = \frac{1}{n} \sum_{i=1}^n 2(y_i - (wx_i + b)) \cdot (-x_i)$$

$$\frac{\partial \mathcal{L}}{\partial b} = \frac{1}{n} \sum_{i=1}^n 2(y_i - (wx_i + b)) \cdot (-1)$$

更新w :

$$w_t = w_{t-1} - \eta \frac{\partial \mathcal{L}}{\partial w_{t-1}}$$

現在這個
時間點的
權重值

↑
↑
上一個的
時間點的
權重值

更新b :


$$b_t = b_{t-1} - \eta \frac{\partial \mathcal{L}}{\partial b_{t-1}}$$

現在這個
時間點的
偏置項


↑
↑
上一個的
時間點的
偏置項



[Recap] 深度學習是在創造非常複雜的空間



weight數量：2



weight數量：3

無限城



weight數量：非常多



更詳細的梯度下降

梯度下降是 $W' = W - LR * \text{梯度}$ ，但需要更多細節


Another training approach: SGD

$$\mathcal{L} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- 在一般的 Gradient descent (GD) 中，我們是將所有的資料算一次梯度之後，才更新一次模型
 - 資料量大的時候，單次模型更新的計算時間長 (但是平行化可以解決)
- SGD: Stochastic gradient descent
 - 把資料切成 batches，每次進行 GD 時都是隨機取其中一個 batch 來計算梯度與更新模型



Mini-batch Data



[定義] Epoch 與 Step

- 定義：
 - **Epoch** 是指模型已經看過整個訓練資料集一次的過程
 - **Step** 是指模型在訓練過程中，執行一次前向傳播與反向傳播 (一次更新權重) 的動作
 - 假設：
 - 我們訓練模型時的 batch_size 為 32，訓練資料集有 3,200 筆
 - 則：
 - 代表 1 個 epoch 有 100 個 steps



Optimization with Batches (Pseudo code)


- 假設 training data 有 5,000,000 examples · batch_size = 1,000
 - Number of steps = $5000000 / 1000 = 5000$
 - 代表會進行 5000 次 gradient descent (更新 5000 次參數)

```
1 for i in range(5000):
2     start_index = i * 1000
3     end_index = start_index + 1000
4     x = train_x[start_index: end_index]
5     y = train_y[start_index: end_index]
6
7     optimizer.zero_grad()
8
9     # Calculate gradients via BP
10    outputs = model(x)
11    loss.backward()
12    # Do gradient descent (update parameters)
13    optimizer.step()
```



Optimization with Batches

- 初始參數： θ_0



Gradient Descent vs. Stochastic Gradient Descent

這頁的 SGD 是指 **Mini-batch**
Stochastic Gradient Descent

- 計算 $\frac{\partial \mathcal{L}}{\partial w}$ 和 $\frac{\partial \mathcal{L}}{\partial b}$

Gradient Descent:

$$\mathcal{L} = \frac{1}{n} \sum_{i=1}^n (y_i - (wx_i + b))^2$$

全部的 n ，但如果 n 很大時需要計算久，且需要較大的記憶體

Stochastic
Gradient Descent:


$$\mathcal{L} = \frac{1}{m} \sum_{i=1}^m (y_i - (wx_i + b))^2$$

m 改用採樣的 ($m \ll n$)，可能為 8 / 16 / 32 / 64 / 128


這裡的 m 就代表 **batch_size**



Full-batch 與 mini-batch 比較 #1：訓練穩定性



Full-batch 與 mini-batch 比較 #2：記憶體用量



- Typically, during training or test time, we use a small set of data (mini-batch) at one time for running a deep learning model on GPUs.



Question #1

- 和 full batch size 的 GD 比起來，用 mini-batch 方式訓練的效果一定比較好嗎？
- Ans: 對深度學習模型來說，通常比較好，因為 full batch size 的方法 1 個 epoch 只會更新模型一次，容易跑到 **local minimum** 的位置




Figure source:
https://en.wikipedia.org/wiki/Maximum_and_minimum



Full-batch and mini-batch GD 比較表格

本堂課講的 SGD

	Batch Gradient Descent	Stochastic Gradient Descent	Mini-batch Stochastic Gradient Descent
單次更新所使用的訓練資料筆數	Entire training set	1	mini_batch_size (Hyperparameter)
訓練穩定性	Stable	Low	Medium
訓練時期更新頻率 (number of steps)	Low 1 time per epoch	High 1 time per sample	Medium 1 time per mini-batch
缺點	(1) High computational and memory cost per update (2) No stochastic gradient noise	Training variance is too big	Hard to determine the best batch size

廣義上 SGD 指的是 Mini-batch Stochastic Gradient Descent



Question #2

- batch_size 大比較好還是 batch_size 小比較好？

SB: small batch (256)

LB: large batch (training set size*0.1)

Table 2: Performance of small-batch (SB) and large-batch (LB) variants of ADAM on the 6 networks listed in Table 1

Name	Training Accuracy		Testing Accuracy	
	SB	LB	SB	LB
F_1	99.66% $\pm$ 0.05%	99.92% $\pm$ 0.01%	98.03% $\pm$ 0.07%	97.81% $\pm$ 0.07%
F_2	99.99% $\pm$ 0.03%	98.35% $\pm$ 2.08%	64.02% $\pm$ 0.2%	59.45% $\pm$ 1.05%
C_1	99.89% $\pm$ 0.02%	99.66% $\pm$ 0.2%	80.04% $\pm$ 0.12%	77.26% $\pm$ 0.42%
C_2	99.99% $\pm$ 0.04%	99.99% $\pm$ 0.01%	89.24% $\pm$ 0.12%	87.26% $\pm$ 0.07%
C_3	99.56% $\pm$ 0.44%	99.88% $\pm$ 0.30%	49.58% $\pm$ 0.39%	46.45% $\pm$ 0.43%
C_4	99.10% $\pm$ 1.23%	99.57% $\pm$ 1.84%	63.08% $\pm$ 0.5%	57.81% $\pm$ 0.17%




Small-batch vs. Large-batch Training

	Small batches	Large batches
單次更新所需要的時間	較短	較長 (平行化後差異縮小)
單次更新記憶體用量	較少	較多
訓練穩定性	較不穩定	較穩定
訓練時期更新頻率 (number of steps)	較多	較少
1 Epoch 訓練時間	較快	較慢 (平行化後較快)
訓練後的模型效能	可能較好	可能較差




Loss function 到底長怎樣？

- 使用 $f(x) = 1/2x^2$ 作為簡單範例



Even more complicated ...



← The loss surfaces of ResNet-56
with/without skip connections.

<https://arxiv.org/abs/1712.09913>
Li, Hao, et al. "Visualizing the loss landscape of neural nets."
Advances in neural information processing systems 31 (2018).




Saddle Point 定義

💡 Saddle point (鞍點) 指一個非 local minimum 的駐點。

鞍點

梯度為零，但它不是最低點，也不是最高點

$$f(x, y) = x^2 - y^2$$



- 沿 x 方向：最低點
- 沿 y 方向：最高點
- 鞍點： $\nabla f(0, 0) = 0$

- 所以如果只看 gradient，你會覺得原點「Gradient = 0，沒有方向可以走了。」
- 但它不是 local minimum。因為沿著 x 方向：原點看起來是最低點；可是沿著 y 方向：原點反而是最高點



SGD Problem #1 (紅色代表解決策略)

- SGD 在訓練過程中是使用隨機的 mini-batch 進行最佳化
- 如果隨機取到的 mini-batch 突然產生很大的梯度，可能使訓練不穩定

Gradient descent: $x_{t+1} = x_t - \eta \nabla_x f(x_t)$

訓練不穩定代表 x_{t+1} 在不該
改變很多的情況下改變太多


觀察梯度歷史紀錄：過去的時間點如果梯度小的話，現在這個時間點理論上梯度不該太大

調整學習率，該大的時候大一點，該小的時候小一點




SGD Problem #2 : 容易卡住在梯度小的點

1. Local maximum / minimum



2. Saddle Point



Saddle Point
(鞍點)

Figure source:

https://en.wikipedia.org/wiki/Maximum_and_minimum

https://en.wikipedia.org/wiki/Saddle_point



Optimizers

基於梯度下降的最佳化方法

Optimizer 定義

- 💡 Optimizer: an algorithm that updates model parameters to minimize an objective function.
- 在 Deep Learning 裡，**Optimizer**（最佳化方法）可以被定義成：
 - 根據目前的 **loss gradient**，決定模型參數要如何更新的演算法
- Gradient 告訴我們「哪邊是上坡」，optimizer 決定「要怎麼往下走」
- SGD 也是一種 optimizer



如何有效訓練深度學習模型？

More Optimizers:

- 對梯度動手腳
 - Momentum
 - ~~Nesterov Momentum~~(不常用)
- 自動調整學習率
 - Adagrad
 - RMSprop
 - Adam



Momentum

https://pytorch.org/docs/main/_modules/torch/optim/sgd.html#SGD

- Momentum 將過去的梯度記錄下來
- 每次更新參數時，會考慮到上一個時間點的梯度
 - 同方向 -> 參數改變幅度大一點；不同方向 -> 參數改變幅度小一點

Gradient descent: $x_{t+1} = x_t - \eta \nabla_x f(x_t)$

Momentum:

$$v_t = \gamma v_{t-1} + \eta \nabla_x f(x_t)$$

上一個時間點的梯度


Momentum term
(超參數，常設為 0.9)

$$x_{t+1} = x_t - v_t$$




[Recap] 以兩個點來觀察 Gradient Descent 的特性

$$x' = x - \eta \nabla_x f(x)$$



SGD + Momentum (example)

(Point 1 -> Point 2 -> Point 3)



SGD + Momentum:

$$v_t = \gamma v_{t-1} + \eta \nabla_x f(x_t)$$


$$x_{t+1} = x_t - v_t$$

	P1
Gradient	-3.5
Past (v_{t-1})	-4
x 改變量 (GD)	→
x 改變量 (Momentum)	→
x 總改變量	→



SGD + Momentum (example)

(Point 1 -> Point 2 -> Point 3)



SGD + Momentum:

$$v_t = \gamma v_{t-1} + \eta \nabla_x f(x_t)$$

$$x_{t+1} = x_t - v_t$$


	P1	P2
Gradient	-3.5	0
Past (v_{t-1})	-4	-2
x 改變量 (GD)	→	
x 改變量 (Momentum)	→	→
x 總改變量	→	→

最低點



SGD + Momentum (example)

(Point 1 -> Point 2 -> Point 3)



SGD + Momentum:

$$v_t = \gamma v_{t-1} + \eta \nabla_x f(x_t)$$


$$x_{t+1} = x_t - v_t$$

	P1	P2	P3
Gradient	-3.5	0	1
Past (v_{t-1})	-4	-2	-2
x 改變量 (GD)	→		←
x 改變量 (Momentum)	→	→	→
x 總改變量	→	→	→

最低點



Momentum



Summary of Momentum

- SGD 可能因為隨機採樣而梯度大幅震盪，而 Momentum 可以緩衝這種震盪
- Momentum 增加歷史紀錄的功能可以：
 - 加速收斂 -> 解決 SGD Problem #1
 - 逃離 Saddle point -> 解決 SGD Problem #2
 - 但 Momentum 也可能超過 convergence

只是理論，不一定能夠做到！(Deep Learning 是很複雜的 function)




如何有效訓練深度學習模型？

Optimizer:

- 對梯度動手腳
 - Momentum
 - Nesterov Momentum
- 自動調整學習率
 - Adagrad
 - RMSprop
 - Adam



Learning rate 應該依據不同參數而不同



w_1 方向的梯度通常較大 (從 loss function 的橢圓形可觀察到)

w_2 方向的梯度通常較小



Adagrad (Adaptative Gradient)

Journal of Machine Learning Research 12 (2011) 2121-2159

Submitted 3/10; Revised 3/11; Published 7/11

Adaptive Subgradient Methods for Online Learning and Stochastic Optimization*

John Duchi

*Computer Science Division
University of California, Berkeley
Berkeley, CA 94720 USA*

JDUCHI@CS.BERKELEY.EDU

Elad Hazan

*Technion - Israel Institute of Technology
Technion City
Haifa, 32000, Israel*

EHAZAN@IE.TECHNION.AC.IL

Yoram Singer

*Google
1600 Amphitheatre Parkway
Mountain View, CA 94043 USA*

SINGER@GOOGLE.COM

Editor: Tong Zhang

Duchi, John, Elad Hazan, and Yoram Singer. "Adaptive subgradient methods for online learning and stochastic optimization." Journal of machine learning research 12.7 (2011).



Adagrad (Adaptative Gradient)

- Adagrad 可以根據歷史梯度總和自動調整 **learning rate**
 - 需要一個 r 來記錄歷史梯度 (平方和)

Gradient descent:
$$x_{t+1} = x_t - \eta \nabla_x f(x_t)$$

Adagrad:
$$x_{t+1} = x_t - \frac{\eta}{\delta + \sqrt{r_t}} \nabla_x f(x_t)$$

$$r_t = r_{t-1} + g \odot g \quad \text{其中 } g = \nabla_x f(x_t)$$

- δ 是一個很小的數字，讓分母不要為0



Element-wise Scaling

- 在多維度情況 (有多個變數 x , Multivariate) 下，梯度是所有偏導數的向量：

$$\nabla_x f = \left[\frac{\partial f}{\partial x_1}, \quad \dots, \quad \frac{\partial f}{\partial x_n} \right]$$

↑ ↑ ↑

每個項的 g 都不同，進而能得出不同 r ，
最終每個項的 **learning rate** 都不同

$$x_{n,t+1} = x_{n,t} - \boxed{\frac{\eta}{\delta + \sqrt{r_{n,t}}}} \nabla_x f(x_{n,t})$$



Element-wise Multiplication

$$r_t = r_{t-1} + \boxed{g \odot g} \quad \text{其中 } g = \nabla_x f(x_t)$$

- 在多維度情況 (有多個變數 x , Multivariate) 下，梯度是所有偏導數的向量：

$$\nabla_x f = \left[\frac{\partial f}{\partial x_1}, \quad \dots, \quad \frac{\partial f}{\partial x_n} \right]$$


$$g \odot g = \left[\left(\frac{\partial f}{\partial x_1} \right)^2, \quad \dots, \quad \left(\frac{\partial f}{\partial x_n} \right)^2 \right]$$



對 Adagrad 的觀察與思考

Adagrad:

$$r_t = r_{t-1} + g \odot g$$

其中 $g = \nabla_x f(x_t)$

$$x_{t+1} = x_t - \frac{\eta}{\delta + \sqrt{r_t}} \nabla_x f(x_t)$$

- 特性：梯度大的學習率自動調小一點；梯度小的學習率自動調大一點
- 缺點：**Learning rate** 或許會下降太快 (因為 r_t 持續累積平方和)
 - 不適用於許多深度學習模型 (實驗角度)



RMSProp (Root Mean Square Propagation)

- RMSProp 是 Adagrad 的改版，為了避免 r 很快就變很大，使得學習率很快就變得很低 (此時神經網路會很難更新)
 - Hinton, Geoffrey, Nitish Srivastava, and Kevin Swersky. "Neural networks for machine learning lecture 6a overview of mini-batch gradient descent." Cited on 14.8 (2012): 2.



RMSProp

Hinton, Geoffrey, Nitish Srivastava, and Kevin Swersky.
"Neural networks for machine learning lecture 6a overview
of mini-batch gradient descent." Cited on 14.8 (2012): 2.

Adagrad:

$$r_t = r_{t-1} + g \odot g$$

其中 $g = \nabla_x f(x_t)$

$$x_{t+1} = x_t - \frac{\eta}{\delta + \sqrt{r_t}} \nabla_x f(x_t)$$

Running average (moving average) · 依照比例抑制 $g \odot g$ 所造成 r 的增長

RMSProp:

$$r_t = \downarrow p r_{t-1} + (1 - \downarrow p) g \odot g$$

p 為 decay rate (常設為 0.9)

$$x_{t+1} = x_t - \frac{\eta}{\sqrt{\delta + r_t}} \nabla_x f(x_t)$$

δ 是一個很小的數字，讓分母不要為0



Adam

- Adam: adaptive moment estimation
- 結合了 Momentum、Adagrad 和 RMSProp 的概念



Kingma, Diederik P., and Jimmy Ba. "Adam: A method for stochastic optimization." ICLR 2015. <https://arxiv.org/abs/1412.6980>

Adam

Kingma, Diederik P., and Jimmy Ba. "Adam: A method for stochastic optimization." ICLR 2015. <https://arxiv.org/abs/1412.6980>

Algorithm 1: *Adam*, our proposed algorithm for stochastic optimization. See section 2 for details, and for a slightly more efficient (but less clear) order of computation. g_t^2 indicates the elementwise square $g_t \odot g_t$. Good default settings for the tested machine learning problems are $\alpha = 0.001$, $\beta_1 = 0.9$, $\beta_2 = 0.999$ and $\epsilon = 10^{-8}$. All operations on vectors are element-wise. With β_1^t and β_2^t we denote β_1 and β_2 to the power t .

Require: α : Stepsize Learning rate

Require: $\beta_1, \beta_2 \in [0, 1)$: Exponential decay rates for the moment estimates

Require: $f(\theta)$: Stochastic objective function with parameters θ

Require: θ_0 : Initial parameter vector

$m_0 \leftarrow 0$ (Initialize 1st moment vector)

$v_0 \leftarrow 0$ (Initialize 2nd moment vector)

$t \leftarrow 0$ (Initialize timestep)

while θ_t not converged **do**

$t \leftarrow t + 1$

$g_t \leftarrow \nabla_{\theta} f_t(\theta_{t-1})$ (Get gradients w.r.t. stochastic objective at timestep t)

$m_t \leftarrow \beta_1 \cdot m_{t-1} + (1 - \beta_1) \cdot g_t$ (Update biased first moment estimate)

$v_t \leftarrow \beta_2 \cdot v_{t-1} + (1 - \beta_2) \cdot g_t^2$ (Update biased second raw moment estimate)

$\hat{m}_t \leftarrow m_t / (1 - \beta_1^t)$ (Compute bias-corrected first moment estimate)

$\hat{v}_t \leftarrow v_t / (1 - \beta_2^t)$ (Compute bias-corrected second raw moment estimate)

$\theta_t \leftarrow \theta_{t-1} - \alpha \cdot \hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon)$ (Update parameters)

end while

return θ_t (Resulting parameters)

Momentum

Adagrad, RMSProp

[Adam]

m 記錄梯度

v 記錄梯度平方

移動平均取自 RMSProp

Adagrad



訓練初期的問題

[Adam]
 m 記錄梯度
 v 記錄梯度平方

假設 $\beta_1 = 0.9$

Momentum 歷史記錄

$$m_t = \underset{0}{\beta_1} m_{\underset{0.1}{t-1}} + (1 - \underset{0.5}{\beta_1}) \nabla_x f(x_t)$$

$\hat{m}_t \leftarrow m_t / (1 - \beta_1^t)$ (Compute bias-corrected first moment estimate)

$\hat{v}_t \leftarrow v_t / (1 - \beta_2^t)$ (Compute bias-corrected second raw moment estimate)

$\theta_t \leftarrow \theta_{t-1} - \alpha \cdot \hat{m}_t / (\sqrt{\hat{v}_t} + \epsilon)$ (Update parameters)

(以 β_1^t 為例)

$$\beta_1^t = \beta_1^1 \times \beta_1^2 \times \cdots \times \beta_1^t$$

$\beta_1^t = 0.9$	無校正 (即 m_t)	校正後
$\hat{m}_t$	$0.1 * 0.5 = 0.05$	$0.1 * 0.5 / 0.1 = 0.5$



代表訓練初期參數更新幅度小 😞



訓練初期的問題 (t 次項)

[Adam]
 m 記錄梯度
 v 記錄梯度平方

$\hat{m}_t \leftarrow m_t / (1 - \beta_1^t)$ (Compute bias-corrected first moment estimate)

$$\beta_1^t = \beta_1^1 \times \beta_1^2 \times \dots \times \beta_1^t$$

t	β_1^t	校正項 $1 - \beta_1^t$
1	0.9	0.1
2	$0.9^2 = 0.81$	0.19
3	$0.9^3 = 0.729$	0.271
10	$0.9^{10} = 0.3487$	0.6513
100	$0.9^{100} = 0.000026$	0.999974

$1 - \beta_1^t$ 越來越接近1

代表隨著訓練時間增加，
越來越不需要校正



比較參數更新

[Adam]
 m 記錄梯度
 v 記錄梯度平方

Adam:

$$\theta_t \leftarrow \theta_{t-1} - \alpha \cdot \widehat{m}_t / (\sqrt{\widehat{v}_t} + \epsilon) \text{ (Update parameters)}$$

其中 α 是學習率

Momentum:

$$v_t = \gamma v_{t-1} + \eta \nabla_x f(x_t)$$

其中 η 是學習率

$$x_{t+1} = x_t - v_t$$

Adagrad:

$$r_t = r_{t-1} + g \odot g$$

其中 $g = \nabla_x f(x_t)$

$$x_{t+1} = x_t - \frac{\eta}{\delta + \sqrt{r_t}} \nabla_x f(x_t)$$

再加上移動平均紀錄的概念，Adam 是 Momentum, RMSProp, Adagrad 的集大成





<https://x.com/DBahdanau/status/1916666861808456176>

AdamW will be in Week 7

The paper of AdamW:

Published as a conference paper at ICLR 2019

DECOUPLED WEIGHT DECAY REGULARIZATION

Ilya Loshchilov & Frank Hutter

University of Freiburg

Freiburg, Germany,

{ilya, fh}@cs.uni-freiburg.de


Week7: 過擬合、正規化、模型訓練技巧、期末專案介紹



訓練完成之後

Convergence

- Convergence (收斂) 是指在模型訓練過程中，loss 的變化逐漸趨於穩定，可能已經到達最佳解，表示模型的學習進度減緩
- 收斂表示模型可能已達到某個局部或全局最小值，但不一定代表它找到了最佳解 (因為有可能只是局部最小值)，也不保證模型此時具備良好的泛化能力 (val_loss 也同樣很低)



Convergence and gradients

- 在經過很多個 steps (t 很大) 的更新之後，gradients 等於零的情況：

$$\nabla_{\theta_t} \mathcal{L}(\theta_t) = 0$$

- $\mathcal{L}$: loss function
- θ_t : 在 t 個時間點 (step) 的的參數組合 (包含各層的w跟b)
- $\nabla_{\theta_t} \mathcal{L}(\theta_t)$: 梯度

此時代表模型可能已經達到目標函數的最佳解



Additional Links

- Optimizers
 - <https://www.ruder.io/optimizing-gradient-descent/#fn5>
- Saddle point
 - https://www.youtube.com/watch?v=8aAU4r_pUUU
- Deep Learning Book Chapter 8
 - <https://www.deeplearningbook.org/contents/optimization.html>



Thank you!

Instructor: 林英嘉

 yjlin@cgu.edu.tw

TA: 鄭茹云

 m1461010@cgu.edu.tw